


# Введение в искусственный интеллект. Машинное обучение

Тема: Метод ближайших соседей в задачах классификации и регрессии

Бабин Д.Н., Иванов И.Е.

кафедра Математической Теории Интеллектуальных Систем



- 1 Метод ближайших соседей в задаче классификации
- 2 Теорема о среднем риске метода ближайшего соседа
- 3 Непараметрическая регрессия
- 4 Методы поиска ближайшего соседа

## Параметрические методы

- исходят из предположения, что искомая зависимость имеет некоторый специальный вид с точностью до некоторых параметров
- параметры находятся решением оптимизационной задачи

## Параметрические методы

- исходят из предположения, что искомая зависимость имеет некоторый специальный вид с точностью до некоторых параметров
- параметры находятся решением оптимизационной задачи


## Непараметрические методы

Непараметрические методы – методы не являющиеся параметрическими

- Метрические алгоритмы, ядерные методы

# Основное предположение

- "Близкие" объекты лежат в одном классе
- Близость задаётся метрикой
- Типичный пример <sup>1</sup>



<sup>1</sup>[https://en.wikipedia.org/wiki/K-nearest\\_neighbors\\_algorithm](https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm)

# Метод ближайшего соседа

- Параметр метода: метрика
- Алгоритм: по заданной метрике ищем ближайший объект в обучающей выборке и классифицируем объект так же

# Метод ближайшего соседа

- Параметр метода: метрика
- Алгоритм: по заданной метрике ищем ближайший объект в обучающей выборке и классифицируем объект так же

## Преимущества

- Простота реализации (нет как таковой процедуры обучения в наивной реализации)
- Хорошая интерпретируемость

# Метод ближайшего соседа

- Параметр метода: метрика
- Алгоритм: по заданной метрике ищем ближайший объект в обучающей выборке и классифицируем объект так же

## Преимущества

- Простота реализации (нет как таковой процедуры обучения в наивной реализации)
- Хорошая интерпретируемость

## Недостатки

- Неустойчивость к выбросам
- Неоднозначность классификации при равных расстояниях до двух объектов
- Необходимость хранить всю обучающую выборку
- Алгоритм поиска вычислительно сложен (если обучающая выборка довольно большая)
- Не учитывается значение расстояния



# Метод $k$ ближайших соседей

- Параметр метода: метрика,  $k$
- Алгоритм: по заданной метрике ищем  $k$  ближайших объектов в обучающей выборке и классифицируем объект как большинство из  $k$  объектов


## Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Параметр  $k$  можно оптимизировать по скользящему контролю

## Недостатки

- Неустойчивость к выбросам
- Неоднозначность классификации при равных расстояниях до двух объектов
- Необходимость хранить всю обучающую выборку
- Алгоритм поиска вычислительно сложен (если обучающая выборка довольно большая)
- Не учитывается значение расстояния

# Метод $k$ ближайших соседей



# Метод $k$ ближайших взвешенных соседей

- Параметры метода: метрика,  $k$ , веса
- Алгоритм: по заданной метрике ищем  $k$  ближайших объектов в обучающей выборке и классифицируем объект взвешенным голосованием

## Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Параметр  $k$  можно оптимизировать по скользящему контролю

## Недостатки

- Неустойчивость к выбросам
- Неоднозначность классификации при равных расстояниях до двух объектов
- Необходимость хранить всю обучающую выборку
- Алгоритм поиска вычислительно сложен (если обучающая выборка довольно большая)
- Не учитывается значение расстояния

- Веса в зависимости от порядкового номера

# Метод k ближайших взвешенных соседей: выбор весов

- Веса в зависимости от порядкового номера
  - Линейно убывающие веса

# Метод k ближайших взвешенных соседей: выбор весов

- Веса в зависимости от порядкового номера
  - Линейно убывающие веса
  - Экспоненциально убывающие веса

- Веса в зависимости от порядкового номера
  - Линейно убывающие веса
  - Экспоненциально убывающие веса
  - Любая невозрастающая функция от порядкового номера

# Метод k ближайших взвешенных соседей: выбор весов

- Веса в зависимости от порядкового номера
  - Линейно убывающие веса
  - Экспоненциально убывающие веса
  - Любая невозрастающая функция от порядкового номера
- Веса в зависимости от расстояния



# Метод k ближайших взвешенных соседей: выбор весов

- Веса в зависимости от порядкового номера
  - Линейно убывающие веса
  - Экспоненциально убывающие веса
  - Любая невозрастающая функция от порядкового номера
- Веса в зависимости от расстояния
  - Любая невозрастающая функция от расстояния

# Метод k ближайших взвешенных соседей: выбор весов

- Веса в зависимости от порядкового номера
  - Линейно убывающие веса
  - Экспоненциально убывающие веса
  - Любая невозрастающая функция от порядкового номера
- Веса в зависимости от расстояния
  - Любая невозрастающая функция от расстояния
- Фиксированные веса объектов

# Метод $k$ ближайших взвешенных соседей среди набора эталонов

- Параметры метода: метрика,  $k$ , веса, **метод выбора эталонов**
- Алгоритм: по заданной метрике ищем  $k$  ближайших объектов среди эталонов выбранных из обучающей выборки и классифицируем объект взвешенным голосованием

## Преимущества

- Простота реализации
- Хорошая интерпретируемость
- Параметр  $k$  можно оптимизировать по скользящему контролю

## Недостатки

- Неустойчивость к выбросам
- Неоднозначность классификации при равных расстояниях до двух объектов
- Необходимость хранить всю обучающую выборку
- Алгоритм поиска вычислительно сложен
- Не учитывается значение расстояния

## Задача

Получить примерно такое же качество работы алгоритма при меньшем количестве хранимых данных.

Возможно получить улучшение качества, так как в процессе выбора эталонов будут удалены выбросы.

## Идеи

- Кластеризация объектов
- Жадный алгоритм

# Выбор эталонов кластеризацией $k$ средних (k-means)

## Задача


$$V = \sum_{i=1}^k \sum_{x \in S_i} (x - \mu_i)^2 \rightarrow \min_{S_i},$$

где  $k$  — число кластеров,  $S_i$  — полученные кластеры,  $\mu_i$  — центр масс  $S_i$  кластера.



## Алгоритм

- 1 Случайно выбираются  $k$  элементов из выборки и объявляются центроидами
- 2 Для фиксированных центроидов каждый элемент выборки относится к одному из кластеров
- 3 Для фиксированных кластеров вычисляются центроиды
- 4 Пункты 2,3 повторяются до сходимости




# Примеры 1-пп, 5-пп, 1-пп с выбором эталонов



# Примеры 1-пп, 5-пп, 1-пп с выбором эталонов



# Примеры 1-пп, 5-пп, 1-пп с выбором эталонов





# Примеры 1-пп, 5-пп, 1-пп с выбором эталонов



# Дополнительные модификации: RadiusNN

## Идея

Часть имеет смысл искать соседей на расстоянии не больше чем некоторый радиус  $r$

## Параметр $r$

Вместо входного параметра количества соседей используется радиус



### Теорема (Cover-Hart inequality)

1. Для задачи двухклассовой классификации с функцией потерь  $L(a(x), y) = [a(x) \neq y]$  и непрерывной функцией  $\eta(x) = P(y = 1|x)$  выполнено неравенство:

$$R^* \leq R^{1-NN}(\infty) \leq 2R^*(1 - R^*),$$

где  $R^{1-NN}(n) = E R^n(x)$  — математическое ожидание эмпирического риска метода одного ближайшего соседа для выборки размера  $n$ , а  $R^{1-NN}(\infty) = \lim_{n \rightarrow \infty} R^{1-NN}(n)$ .

<sup>2</sup>Т. М. Cover and P. E. Hart. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13:21–27, January 1967.

### Теорема (Cover-Hart inequality)

1. Для задачи двухклассовой классификации с функцией потерь  $L(a(x), y) = [a(x) \neq y]$  и непрерывной функцией  $\eta(x) = P(y = 1|x)$  выполнено неравенство:

$$R^* \leq R^{1-NN}(\infty) \leq 2R^*(1 - R^*),$$

где  $R^{1-NN}(n) = E R^n(x)$  — математическое ожидание эмпирического риска метода одного ближайшего соседа для выборки размера  $n$ , а  $R^{1-NN}(\infty) = \lim_{n \rightarrow \infty} R^{1-NN}(n)$ .

2. В аналогичных условиях для многоклассовой ( $M$  классов) классификации выполнено

$$R^* \leq R^{1-NN}(\infty) \leq R^* \left( 2 - \frac{M}{M-1} R^* \right).$$

<sup>2</sup>Т. М. Cover and P. E. Hart. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13:21–27, January 1967.

## Доказательство теоремы

$$R^{1-NN} = \lim_{n \rightarrow \infty} R^{1-NN}(n) = \lim_{n \rightarrow \infty} E_{x_0} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) =$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= \lim_{n \rightarrow \infty} R^{1-NN}(n) = \lim_{n \rightarrow \infty} E_{x_0} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = \\ &= E_{x_0} \lim_{n \rightarrow \infty} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{x_0} \lim_{n \rightarrow \infty} R_n(x_0) \end{aligned}$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= \lim_{n \rightarrow \infty} R^{1-NN}(n) = \lim_{n \rightarrow \infty} E_{x_0} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = \\ &= E_{x_0} \lim_{n \rightarrow \infty} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{x_0} \lim_{n \rightarrow \infty} R_n(x_0) \end{aligned}$$

$$R_n(x_0) = E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(y_{(1)}, y_0) =$$



## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= \lim_{n \rightarrow \infty} R^{1-NN}(n) = \lim_{n \rightarrow \infty} E_{x_0} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = \\ &= E_{x_0} \lim_{n \rightarrow \infty} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{x_0} \lim_{n \rightarrow \infty} R_n(x_0) \end{aligned}$$

$$\begin{aligned} R_n(x_0) &= E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(y_{(1)}, y_0) = \\ &= P(y_{(1)} \neq y_0 | x_{(1)}, x_0) = P(y_{(1)} = 0, y_0 = 1 | x_{(1)}, x_0) + P(y_{(1)} = 1, y_0 = 0 | x_{(1)}, x_0) = \end{aligned}$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= \lim_{n \rightarrow \infty} R^{1-NN}(n) = \lim_{n \rightarrow \infty} E_{x_0} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = \\ &= E_{x_0} \lim_{n \rightarrow \infty} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{x_0} \lim_{n \rightarrow \infty} R_n(x_0) \end{aligned}$$

$$\begin{aligned} R_n(x_0) &= E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(y_{(1)}, y_0) = \\ &= P(y_{(1)} \neq y_0 | x_{(1)}, x_0) = P(y_{(1)} = 0, y_0 = 1 | x_{(1)}, x_0) + P(y_{(1)} = 1, y_0 = 0 | x_{(1)}, x_0) = \\ &= P(y_{(1)} = 0 | x_{(1)}) P(y_0 = 1 | x_0) + P(y_{(1)} = 1 | x_{(1)}) P(y_0 = 0 | x_0) = \end{aligned}$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= \lim_{n \rightarrow \infty} R^{1-NN}(n) = \lim_{n \rightarrow \infty} E_{x_0} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = \\ &= E_{x_0} \lim_{n \rightarrow \infty} E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{x_0} \lim_{n \rightarrow \infty} R_n(x_0) \end{aligned}$$

$$\begin{aligned} R_n(x_0) &= E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(a(x_0), y_0) = E_{y_0|x_0} E_{x_1, x_2, \dots, x_n} L(y_{(1)}, y_0) = \\ &= P(y_{(1)} \neq y_0 | x_{(1)}, x_0) = P(y_{(1)} = 0, y_0 = 1 | x_{(1)}, x_0) + P(y_{(1)} = 1, y_0 = 0 | x_{(1)}, x_0) = \\ &= P(y_{(1)} = 0 | x_{(1)}) P(y_0 = 1 | x_0) + P(y_{(1)} = 1 | x_{(1)}) P(y_0 = 0 | x_0) = \\ &= (1 - \eta(x_{(1)})) \eta(x_0) + \eta(x_{(1)}) (1 - \eta(x_0)) \end{aligned}$$

## Доказательство теоремы

$$R^{1-NN} = E_{x_0} \lim_{n \rightarrow \infty} ((1 - \eta(x_{(1)}))\eta(x_0) + \eta(x_{(1)})(1 - \eta(x_0))) =$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= E_{x_0} \lim_{n \rightarrow \infty} ((1 - \eta(x_{(1)}))\eta(x_0) + \eta(x_{(1)})(1 - \eta(x_0))) = \\ &= E_{x_0} [2\eta(x_0)(1 - \eta(x_0))] = E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] \end{aligned}$$

$$R^{1-NN} = E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] =$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= E_{x_0} \lim_{n \rightarrow \infty} ((1 - \eta(x_{(1)}))\eta(x_0) + \eta(x_{(1)})(1 - \eta(x_0))) = \\ &= E_{x_0} [2\eta(x_0)(1 - \eta(x_0))] = E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] \end{aligned}$$

$$\begin{aligned} R^{1-NN} &= E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] = \\ &= 2E_{x_0} [R^*(x_0)] - 2E_{x_0} [(R^*(x_0))^2] = \end{aligned}$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= E_{x_0} \lim_{n \rightarrow \infty} ((1 - \eta(x_{(1)}))\eta(x_0) + \eta(x_{(1)})(1 - \eta(x_0))) = \\ &= E_{x_0} [2\eta(x_0)(1 - \eta(x_0))] = E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] \end{aligned}$$

$$\begin{aligned} R^{1-NN} &= E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] = \\ &= 2E_{x_0} [R^*(x_0)] - 2E_{x_0} [(R^*(x_0))^2] = \\ &= 2R^* - 2(R^*)^2 - 2D_{x_0} R^*(x_0) = 2R^*(1 - R^*) - 2D_{x_0} R^*(x_0) \leq 2R^*(1 - R^*) \end{aligned}$$

## Доказательство теоремы

$$\begin{aligned} R^{1-NN} &= E_{x_0} \lim_{n \rightarrow \infty} ((1 - \eta(x_{(1)}))\eta(x_0) + \eta(x_{(1)})(1 - \eta(x_0))) = \\ &= E_{x_0} [2\eta(x_0)(1 - \eta(x_0))] = E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] \end{aligned}$$

$$\begin{aligned} R^{1-NN} &= E_{x_0} [2R^*(x_0)(1 - R^*(x_0))] = \\ &= 2E_{x_0} [R^*(x_0)] - 2E_{x_0} [(R^*(x_0))^2] = \\ &= 2R^* - 2(R^*)^2 - 2D_{x_0} R^*(x_0) = 2R^*(1 - R^*) - 2D_{x_0} R^*(x_0) \leq 2R^*(1 - R^*) \end{aligned}$$

Нижняя оценка:

$$R^{1-NN} = 2E_{x_0} [R^*(x_0)] \geq R^*,$$

так как  $R^* \leq 0.5$ , что и завершает доказательство



# Средний риск метода ближайшего соседа

## Лемма1.

Пусть  $x_0, x_1, \dots, x_n$  — независимые одинаково распределенные случайные величины. Тогда  $x_{(1)} \rightarrow x_0$  с вероятностью 1 при  $n \rightarrow \infty$ .

## Лемма 2.

Пусть  $\eta(x) = p(y = +1|x)$ . Тогда

$$R^*(x) = \min(\eta(x), 1 - \eta(x))$$



## Теорема (Cover-Hart inequality)

1. Для задачи двухклассовой классификации с функцией потерь  $L(a(x), y) = [a(x) \neq y]$  и непрерывной функцией  $\eta(x) = P(y = 1|x)$  выполнено неравенство:

$$R^* \leq R^{1-NN}(\infty) \leq 2R^*(1 - R^*),$$

где  $R^{1-NN}(n) = E R^n(x)$  — математическое ожидание эмпирического риска метода одного ближайшего соседа для выборки размера  $n$ , а  $R^{1-NN}(\infty) = \lim_{n \rightarrow \infty} R^{1-NN}(n)$ .

2. В аналогичных условиях для многоклассовой ( $M$  классов) классификации выполнено

$$R^* \leq R^{1-NN}(\infty) \leq R^* \left( 2 - \frac{M}{M-1} R^* \right).$$



# Средний риск метода ближайшего соседа

## Теорема (Cover-Hart inequality)

1. Для задачи двухклассовой классификации с функцией потерь  $L(a(x), y) = [a(x) \neq y]$  и непрерывной функцией  $\eta(x) = P(y = 1|x)$  выполнено неравенство:

$$R^* \leq R^{1-NN}(\infty) \leq 2R^*(1 - R^*),$$

где  $R^{1-NN}(n) = E R^n(x)$  — математическое ожидание эмпирического риска метода одного ближайшего соседа для выборки размера  $n$ , а  $R^{1-NN}(\infty) = \lim_{n \rightarrow \infty} R^{1-NN}(n)$ .

2. В аналогичных условиях для многоклассовой ( $M$  классов) классификации выполнено

$$R^* \leq R^{1-NN}(\infty) \leq R^* \left( 2 - \frac{M}{M-1} R^* \right).$$

## Следствие

Если  $R^* = 0$  или  $R^* = \frac{1}{2}$ , то  $R^{1-NN}(\infty) = R^*$ .

- Метод ближайших соседей – простой и хорошо интерпретируемый метод классификации

- Метод ближайших соседей – простой и хорошо интерпретируемый метод классификации
- Метод имеет большое число вариаций для настройки

- Метод ближайших соседей – простой и хорошо интерпретируемый метод классификации
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)

- Метод ближайших соседей – простой и хорошо интерпретируемый метод классификации
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)
  - Число ближайших соседей

- Метод ближайших соседей – простой и хорошо интерпретируемый метод классификации
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)
  - Число ближайших соседей
  - Веса во взвешенном варианте метода



- Метод ближайших соседей – простой и хорошо интерпретируемый метод классификации
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)
  - Число ближайших соседей
  - Веса во взвешенном варианте метода
  - Алгоритм подбора эталонов



- Главный минус параметрических моделей, что для описания зависимости необходимо иметь параметрическую модель

- Главный минус параметрических моделей, что для описания зависимости необходимо иметь параметрическую модель
- В случае невозможности подбора адекватной модели имеет смысл пользоваться непараметрическими регрессионными методами

- Главный минус параметрических моделей, что для описания зависимости необходимо иметь параметрическую модель
- В случае невозможности подбора адекватной модели имеет смысл пользоваться непараметрическими регрессионными методами

## Предположение

Близким объектам соответствуют близкие ответы

## Простейшая модель

Приближаем искомую зависимость константой в некоторой окрестности

## Формула Надарая-Ватсона

Если в окрестности точки несколько объектов из обучающей выборки, то разумно использовать взвешенное среднее в качестве предсказания алгоритма


$$a(x) = \frac{\sum_i y_i \omega_i(x)}{\sum_i \omega_i(x)},$$

где  $\omega_i(x) = K_h(x, x_i)$ , а функция  $K_h$  называется ядром с шириной окна сглаживания  $h$ .



# Примеры ядер

- $K_h(x, x_i) = K\left(\frac{\|x - x_i\|}{h}\right)$
- Типичные примеры <sup>3</sup>



<sup>3</sup>[https://ru.wikipedia.org/wiki/Ядро\\_\(статистика\)](https://ru.wikipedia.org/wiki/Ядро_(статистика))

# Напоминание: Вывод выражения среднеквадратичной ошибки

## Определения

Пусть  $y = y(x) = f(x) + \varepsilon$  — целевая зависимость, где  $f(x)$  — детерминированная функция,  $\varepsilon \sim N(0, \sigma^2)$  и  $a(x)$  — алгоритм машинного обучения.



# Напоминание: Вывод выражения среднеквадратичной ошибки

## Определения

Пусть  $y = y(x) = f(x) + \varepsilon$  — целевая зависимость, где  $f(x)$  — детерминированная функция,  $\varepsilon \sim N(0, \sigma^2)$  и  $a(x)$  — алгоритм машинного обучения.

Полагаем, что  $\varepsilon$  и  $a$  — независимые ( $Ea\varepsilon = EaE\varepsilon$ ).  $Ey = Ef$ ,  $Dy = D\varepsilon = \sigma^2$ .

## Разложение квадрата ошибки

$$\begin{aligned} E(y - a)^2 &= E(y^2 + a^2 - 2ya) = Ey^2 + Ea^2 - 2Eya = \\ &= Ey^2 + Ea^2 - 2E(f + \varepsilon)a = Ey^2 + Ea^2 - 2Efa - 2E\varepsilon a = \\ &= Ey^2 - (Ey)^2 + (Ey)^2 + Ea^2 - (Ea)^2 + (Ea)^2 - 2fEa = \\ &= Dy + Da + (Ey)^2 + (Ea)^2 - 2fEa = Dy + Da + (Ef)^2 - 2fEa + (Ea)^2 = \\ &= Dy + Da + (E(f - a))^2 = \sigma^2 + \text{variance}(a) + \text{bias}^2(f, a) \end{aligned}$$

## Разброс

$$\begin{aligned} \text{Variance}(a) &= D \left( \frac{1}{k} \sum_{i=1}^k y(x_{(i)}) \right) = \frac{1}{k^2} D \left( \sum_{i=1}^k y(x_{(i)}) \right) = \\ &= \frac{1}{k^2} D \left( \sum_{i=1}^k (f(x_{(i)}) + \varepsilon_i) \right) = \frac{1}{k^2} D \left( \sum_{i=1}^k f(x_{(i)}) \right) + \frac{1}{k^2} D \left( \sum_{i=1}^k \varepsilon_i \right) = \\ &= 0 + \frac{1}{k^2} k \sigma^2 = \frac{\sigma^2}{k} \end{aligned}$$

# Разброс и смещение для kNN

## Разброс

$$\begin{aligned} \text{Variance}(a) &= D \left( \frac{1}{k} \sum_{i=1}^k y(x_{(i)}) \right) = \frac{1}{k^2} D \left( \sum_{i=1}^k y(x_{(i)}) \right) = \\ &= \frac{1}{k^2} D \left( \sum_{i=1}^k (f(x_{(i)}) + \varepsilon_i) \right) = \frac{1}{k^2} D \left( \sum_{i=1}^k f(x_{(i)}) \right) + \frac{1}{k^2} D \left( \sum_{i=1}^k \varepsilon_i \right) = \\ &= 0 + \frac{1}{k^2} k \sigma^2 = \frac{\sigma^2}{k} \end{aligned}$$

## Смещение

$$\text{bias}^2(f, a) = (E(f(x_0) - a(x_0)))^2 = \left( f(x_0) - \frac{1}{k} \sum_{i=1}^k f(x_{(i)}) \right)^2$$

# Bias-variance разложение для kNN

$$Error(x_0) = E(a(x_0) - f(x_0))^2 = \left( f(x_0) - \frac{1}{k} \sum_{i=1}^k f(x_{(i)}) \right)^2 + \frac{\sigma^2}{k} + \sigma^2$$

- С ростом  $k$  разброс уменьшается
- С ростом  $n$  смещение уменьшается

- Главное преимущество непараметрической регрессии — это отсутствие предположений о виде модели зависимости

- Главное преимущество непараметрической регрессии — это отсутствие предположений о виде модели зависимости
- Метод имеет большое число вариаций для настройки

- Главное преимущество непараметрической регрессии — это отсутствие предположений о виде модели зависимости
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)

- Главное преимущество непараметрической регрессии — это отсутствие предположений о виде модели зависимости
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)
  - Число ближайших соседей



- Главное преимущество непараметрической регрессии — это отсутствие предположений о виде модели зависимости
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)
  - Число ближайших соседей
  - Веса во взвешенном варианте метода

- Главное преимущество непараметрической регрессии — это отсутствие предположений о виде модели зависимости
- Метод имеет большое число вариаций для настройки
  - Подбор метрики (metric learning)
  - Число ближайших соседей
  - Веса во взвешенном варианте метода
  - Ширину окна сглаживания



Где могут быть полезны методы поиска ближайших соседей?



## Точные

- Полный перебор
- К-мерное дерево (KD-tree)
- Метрическое дерево (ball-tree)

---

<sup>4</sup><https://arxiv.org/abs/1603.09320>



## Точные

- Полный перебор
- К-мерное дерево (KD-tree)
- Метрическое дерево (ball-tree)

## Приближенные

- Locality sensitive hashing (LSH)
- Navigable Small World (NSW)
- HNSW <sup>4</sup>

---


<sup>4</sup><https://arxiv.org/abs/1603.09320>

## Алгоритм построения


- 1 Если количество элементов меньше некоторого порогового значения, то отбивается лист и в него помещаются все элементы, в противном случае переходим к следующему пункту
- 2 Случайно выбирается признак, по которому будет разделение. По этому признаку ищется медиана
- 3 Все объекты с выбранным признаком левее медианы идет в левое поддерево, остальные в правое
- 4 Для левого и правого поддерева применяется та же процедура построения

<sup>5</sup>Bentley, J. L. (1975). Multidimensional binary search trees used for associative searching. Communications of the ACM. 18 (9): 509–517. doi:10.1145/361002.361007

# K-мерное дерево



Kd-Tree in 2D



Multiple Randomized Kd-Trees



# Поиск ближайшего соседа в $K$ -мерном дереве

## Алгоритм поиска I

Для нашего запроса идём по дереву и в соответствующем листе ищем нужное количество ближайших соседей

# Поиск ближайшего соседа в $K$ -мерном дереве

## Алгоритм поиска I

Для нашего запроса идём по дереву и в соответствующем листе ищем нужное количество ближайших соседей

## Идея

Если расстояние до дальнего ближайшего соседа меньше, чем расстояние до разделяющей гиперплоскости, то это означает, что во втором поддереве ближайших соседей нет.

# Поиск ближайшего соседа в K-мерном дереве

## Алгоритм поиска I

Для нашего запроса идём по дереву и в соответствующем листе ищем нужное количество ближайших соседей

## Идея

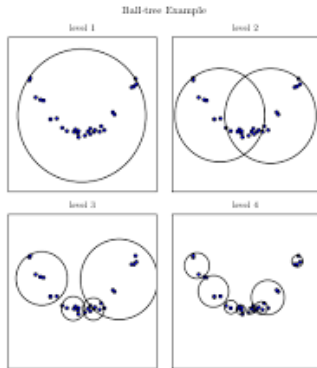
Если расстояние до дальнего ближайшего соседа меньше, чем расстояние до разделяющей гиперплоскости, то это означает, что во втором поддереве ближайших соседей нет.

## Алгоритм поиска II

- 1 Выполняем шаги алгоритма I, считая в каждой вершине расстояние до разделяющей гиперплоскости
- 2 Делаем обратный ход алгоритма, если расстояние до разделяющей гиперплоскости меньше, чем расстояние до дальнего ближайшего соседа

## Идея

Использовать вместо полугиперплоскостей шары



<sup>6</sup>Omohundro, Stephen M. (1989), Five Balltree Construction Algorithms


# Locality Sensitive Hashing (LSH) <sup>7</sup>

## Идея

Разделить пространство, используя хэш-функции

## Пример

В качестве семейства функций можно рассмотреть гиперплоскости



<sup>7</sup><https://codeforces.com/blog/entry/54080?locale=ru>


# Locality Sensitive Hashing (LSH) <sup>7</sup>

## Идея

Разделить пространство, используя хэш-функции

## Пример

В качестве семейства функций можно рассмотреть гиперплоскости



<sup>7</sup><https://codeforces.com/blog/entry/54080?locale=ru>


# Жадные алгоритмы на графе

## Жадный алгоритм

Итеративно ищем ближайшего соседа в графе

## Теорема


Для графа Делоне жадный алгоритм решает задачу поиска ближайшего соседа точно



# Navigable Small World (NSW) <sup>8</sup>

## Идея

Поиск по графу типа Small World



## Гарантии


Теоретических гарантий нет, поэтому алгоритм поиска запускают несколько раз в зависимости от требуемой точности

<sup>8</sup>Y. Malkov, A. Ponomarenko, A. Logvinov, and V. Krylov, Approximate nearest neighbor algorithm based on navigable small world graphs, Information Systems, vol. 45, pp. 61-68, 2014.




## Идея

В графе типа Small World можно выделить подграфы меньшего размера и сделать поиск итеративным



<sup>9</sup><https://arxiv.org/abs/1603.09320>

# Сравнение методов поиска ближайших соседей <sup>10</sup>



<sup>10</sup><https://github.com/erikbern/ann-benchmarks>

- Метод поиска ближайших соседей — важная задача теории алгоритмов
- Нужно помнить, что есть методы в среднем быстрее, чем полный перебор
- Для современных индустриальных систем характерно использование не точных, но очень быстрых алгоритмов поиска



Спасибо за внимание!