

# Введение в искусственный интеллект.

## Машинное обучение

### Тема: Линейная регрессия

Бабин Д.Н., Иванов И.Е.

кафедра Математической Теории Интеллектуальных Систем



- 1 Оптимальный байесовский регрессор
- 2 Линейная регрессии с точки зрения ML и MAP оценивания
- 3 Регуляризация: гребневая регрессия, LASSO, ElasticNet
- 4 Метрики качества для задачи регрессии

# Напоминание: вероятностная постановка задач машинного обучения

## Предположения

Пусть известно совместное распределение  $p(x, y)$  на  $X \times Y$

Пусть задана функция потерь  $L(a(x), y)$

## Определение

Средняя величина потерь для алгоритма  $a(x)$

$$R(a) = \iint L(a(x), y) dP(x, y) = \iint L(a(x), y) p(x, y) dx dy$$

## Задача

Найти такой  $a^*(x)$ , что  $a^*(x) = \arg \min_a R(a)$ .

Будем называть модель  $a^*$  оптимальной и  $R^*$  — значение оптимального среднего риска.

# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$



# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

## Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$

# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

## Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$

## Доказательство

$$E((y - a(x))^2|x) = E((y - E(y|x) + E(y|x) - a(x))^2|x) =$$

# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

## Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$

## Доказательство

$$\begin{aligned} E((y - a(x))^2|x) &= E((y - E(y|x) + E(y|x) - a(x))^2|x) = \\ &= E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x) - 2E(y - E(y|x)|x)E(a(x) - E(y|x)|x) \end{aligned}$$



# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

## Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$

## Доказательство

$$\begin{aligned} E((y - a(x))^2|x) &= E((y - E(y|x) + E(y|x) - a(x))^2|x) = \\ &= E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x) - 2E(y - E(y|x)|x)E(a(x) - E(y|x)|x) \end{aligned}$$

Последнее слагаемое равно нулю, так как

$$E(y - E(y|x)|x) = E(y|x) - E(E(y|x)|x) = E(y|x) - E(y|x) = 0.$$

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

## Доказательство

$$R(a) = \iint L(a(x), y)p(x, y)dydx = \iint (a(x) - y)^2 p(x, y)dydx =$$

# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

## Доказательство

$$\begin{aligned} R(a) &= \iint L(a(x), y) p(x, y) dy dx = \iint (a(x) - y)^2 p(x, y) dy dx = \\ &= \iint (a(x) - y)^2 p(y|x) dy p(x) dx = \int E((y - a(x))^2 | x) p(x) dx \end{aligned}$$



# Квадратичная функция потерь

## Теорема

Если  $L(a(x), y) = (a(x) - y)^2$ , то величина средних потерь минимальна при

$$a^* = E(y|x)$$

## Доказательство

$$\begin{aligned} R(a) &= \iint L(a(x), y) p(x, y) dy dx = \iint (a(x) - y)^2 p(x, y) dy dx = \\ &= \iint (a(x) - y)^2 p(y|x) dy p(x) dx = \int E((y - a(x))^2 | x) p(x) dx \end{aligned}$$
 Применяя лемму, получаем:  
$$\begin{aligned} R(a) &= \int E((y - a(x))^2 | x) p(x) dx = \int E((y - E(y|x))^2 | x) p(x) dx + \\ &+ \int E((a(x) - E(y|x))^2 | x) p(x) dx \geq \int E((y - E(y|x))^2 | x) p(x) dx, \end{aligned}$$
 что и требовалось доказать.





# Постановка задачи: линейная регрессия


Дано

$$p(y_i|x_i) \sim w^T x_i + \varepsilon_i \sim N(w^T x_i, \sigma^2),$$

для  $i = 1.., \ell$ , где  $w \in \mathbb{R}^{n+1}$ ,  $\varepsilon_i \sim N(0, \sigma^2)$

Задача

Найти  $w$



# Напоминание: два вида оценивания параметров

## Принцип максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$



# Напоминание: два вида оценивания параметров

## Принцип максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

## Принцип максимума апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x, y)$$

# Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

# Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$



# Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$

$$p(y_i|w, x_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$



# Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$

$$p(y_i|w, x_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$

$$w_{ML} = \arg \max_w \prod_i \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right) = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2}$$



# Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$

$$p(y_i|w, x_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$

$$w_{ML} = \arg \max_w \prod_i \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right) = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2}$$

$$w_{ML} = \arg \min_w \sum_i (y_i - w^T x_i)^2$$



## Постановка задачи и допущения

- $X = \mathbb{R}^n$ ,  $Y = \mathbb{R}$

## Постановка задачи и допущения

- $X = \mathbb{R}^n$ ,  $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$ , где  $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$  — параметры модели.



## Постановка задачи и допущения

- $X = \mathbb{R}^n$ ,  $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$ , где  $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$  — параметры модели.
- Удобно писать в векторном виде

$$a(x) = w^T \cdot x,$$

где  $x = (1, x^1, \dots, x^n)^T \in \mathbb{R}^{n+1}$ .

# Метод наименьших квадратов

## Постановка задачи и допущения

- $X = \mathbb{R}^n$ ,  $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$ , где  $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$  — параметры модели.
- Удобно писать в векторном виде

$$a(x) = w^T \cdot x,$$

где  $x = (1, x^1, \dots, x^n)^T \in \mathbb{R}^{n+1}$ .

## Метод наименьших квадратов

- $L(w, X_{train}) = MSE(w, X_{train}) = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2$  — функция потерь

# Метод наименьших квадратов

## Постановка задачи и допущения

- $X = \mathbb{R}^n$ ,  $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$ , где  $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$  — параметры модели.
- Удобно писать в векторном виде

$$a(x) = w^T \cdot x,$$

где  $x = (1, x^1, \dots, x^n)^T \in \mathbb{R}^{n+1}$ .

## Метод наименьших квадратов

- $L(w, X_{train}) = MSE(w, X_{train}) = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2$  — функция потерь
- Задача найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Теорема

Решением задачи  $\arg \min_w \left( \sum_{i=1}^{\ell} (w^T \cdot x_i - y_i)^2 \right)$  является  $\hat{w} = (X^T X)^{-1} \cdot X^T \cdot y$ , где  $X_{i,j} = x_i^j$ ,  $y = (y_1, \dots, y_{\ell})$ .

## Теорема

Решением задачи  $\arg \min_w \left( \sum_{i=1}^{\ell} (w^T \cdot x_i - y_i)^2 \right)$  является  $\hat{w} = (X^T X)^{-1} \cdot X^T \cdot y$ , где  $X_{i,j} = x_i^j$ ,  $y = (y_1, \dots, y_{\ell})$ .

## Доказательство

Запишем задачу в векторном виде  $\|Xw - y\|^2 \rightarrow \min_w$ . Необходимое условие минимума в матричном виде имеет вид:

$$\begin{aligned} \frac{\partial}{\partial w} \|Xw - y\|^2 &= \frac{\partial}{\partial w} \left( (Xw - y)^T \cdot (Xw - y) \right) = \frac{\partial}{\partial w} \left( (Xw)^T Xw - (Xw)^T y - y^T Xw + y^T y \right) = \\ &= \frac{\partial}{\partial w} \left( w^T X^T Xw - w^T X^T y - y^T Xw + y^T y \right) = \frac{\partial}{\partial w} w^T (X^T X)w - 2 \frac{\partial}{\partial w} (X^T y)^T w = 0 \end{aligned}$$

## Определение

Пусть  $w = (w_1, \dots, w_n)$  — вектор столбец, а  $z = z(w_1, \dots, w_n)$ . Тогда определим

$$\frac{\partial z}{\partial w} := \left( \frac{\partial z}{\partial w_1}, \dots, \frac{\partial z}{\partial w_n} \right)^T$$

## Лемма 1

$$\frac{\partial}{\partial x} x^T a = a$$

## Лемма 2

$$\frac{\partial}{\partial x} x^T A x = (A + A^T)x$$

## Теорема

Решением задачи  $\arg \min_w \left( \sum_{i=1}^{\ell} (w^T \cdot x_i - y_i)^2 \right)$  является  $\hat{w} = (X^T X)^{-1} \cdot X^T \cdot y$ , где  $X_{i,j} = x_i^j$ ,  $y = (y_1, \dots, y_{\ell})$ .

## Продолжение доказательства

Необходимое условие минимума в матричном виде имеет вид:

$$\frac{\partial}{\partial w} \|Xw - y\|^2 = \frac{\partial}{\partial w} w^T (X^T X) w - 2 \frac{\partial}{\partial w} (X^T y)^T w =$$

Далее применяем леммы и приравниваем к нулю:

$$= 2X^T Xw - 2X^T y = 0,$$

откуда получаем  $w = (X^T X)^{-1} \cdot X^T \cdot y$ , что и требовалось доказать.

# Полиномиальная регрессия

## Идея

Можно генерировать новые признаки на основе уже имеющихся, применяя нелинейные функции



## Идея

Можно генерировать новые признаки на основе уже имеющихся, применяя нелинейные функции

## Примеры преобразований

- Возведение в степень
- Попарные произведения
- Квадратный корень
- Логарифм
- Экспонента

# Преимущества и недостатки линейной регрессии

## Преимущества

- Простой алгоритм, вычислительно не сложный
- Линейная регрессия хорошо интерпретируемая модель
- Несмотря на свою простоту может описывать довольно сложные зависимости (например, полиномиальные)

# Преимущества и недостатки линейной регрессии

## Преимущества

- Простой алгоритм, вычислительно не сложный
- Линейная регрессия хорошо интерпретируемая модель
- Несмотря на свою простоту может описывать довольно сложные зависимости (например, полиномиальные)

## Недостатки

- Алгоритм предполагает, что все признаки числовые
- Алгоритм предполагает, что данные распределены нормально, что не всегда так
- Алгоритм сильно чувствителен к выбросам





# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$



# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$





# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$

$$w_{MAP} = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2} + \ell \ln p(w)$$



# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$

$$w_{MAP} = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2} + \ell \ln p(w)$$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$



# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$

$$w_{MAP} = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2} + \ell \ln p(w)$$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

В задаче минимизации появилось дополнительное слагаемое, которое зависит только от априорного распределения на веса  $w$

# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$



# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

Предположим, что  $p(w) \sim N(0, \tau^2)$

# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

Предположим, что  $p(w) \sim N(0, \tau^2)$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \frac{\ell w^T w}{2\tau^2}$$



# Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

Предположим, что  $p(w) \sim N(0, \tau^2)$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \frac{\ell w^T w}{2\tau^2}$$

$$w_{MAP} = \arg \min_w \frac{1}{\ell} \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \frac{1}{2\tau^2} \|w\|^2$$







## L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \frac{\alpha}{2} \sum_{i=0}^n w_i^2 = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \frac{\alpha}{2} \sum_{i=0}^n w_i^2$  — функция потерь

## L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \frac{\alpha}{2} \sum_{i=0}^n w_i^2 = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \frac{\alpha}{2} \sum_{i=0}^n w_i^2$  — функция потерь
- Задача найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \frac{\alpha}{2} \sum_{i=0}^n w_i^2 = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \frac{\alpha}{2} \sum_{i=0}^n w_i^2$  — функция потерь
- Задача найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Теорема

Решением задачи  $\arg \min_w (\sum_{i=1}^{\ell} (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n w_i^2)$  является

$\hat{w} = (X^T X + \alpha I_{n+1})^{-1} \cdot X^T \cdot y$ , где  $X_{i,j} = x_i^j$ ,  $y = (y_1, \dots, y_{\ell})$ ,  $I_{n+1}$  — единичная матрица.



# Доказательство теоремы

## Лемма 3

$$\frac{\partial}{\partial x} x^T x = 2x$$

# Доказательство теоремы

## Лемма 3

$$\frac{\partial}{\partial x} x^T x = 2x$$

## Теорема

Решением задачи  $\arg \min_w \left( \sum_{i=1}^{\ell} (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n w_i^2 \right)$  является

$\hat{w} = (X^T X + \alpha I_{n+1})^{-1} \cdot X^T \cdot y$ , где  $X_{i,j} = x_i^j$ ,  $y = (y_1, \dots, y_{\ell})$ ,  $I_{n+1}$  — единичная матрица.

## Доказательство

Запишем задачу в векторном виде  $\|Xw - y\|^2 + \alpha \|w\|^2 \rightarrow \min_w$ . Необходимое условие минимума в матричном виде имеет вид:

$$\frac{\partial}{\partial w} \left( (Xw - y)^T \cdot (Xw - y) + \alpha w^T w \right) = 2X^T Xw - 2X^T y + 2\alpha w = 0$$

- Регуляризация не даёт параметрам модели быть слишком большими
- Как правило регуляризация обеспечивает большую обобщающую способность
- Более устойчива к выбросам
- Появился параметр, который можно настроить при помощи кросс-валидации

# Свойства гребневой регрессии

- Регуляризация не даёт параметрам модели быть слишком большими
- Как правило регуляризация обеспечивает большую обобщающую способность
- Более устойчива к выбросам
- Появился параметр, который можно настроить при помощи кросс-валидации

## Вероятностный смысл параметра $\alpha$

$\alpha = \frac{1}{\tau^2}$ , где  $\tau$  — среднеквадратическое отклонение априорного распределения на  $w$





## L1-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \alpha \sum_{i=0}^n |w_i| = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i|$  — функция потерь

## L1-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \alpha \sum_{i=0}^n |w_i| = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i|$  — функция потерь
- Задача найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$



## L1-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \alpha \sum_{i=0}^n |w_i| = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i|$  — функция потерь
- Задача найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Свойства

- Эта регуляризация обеспечивает отбор признаков
- Нет аналитического решения




## Вероятностный смысл параметра $\alpha$

Параметр  $\alpha$  — обратно пропорционален среднеквадратичному отклонению априорного распределения на  $w$ . В данном случае это распределение Лапласа

$$p(w) = \frac{1}{\tau} \exp\left(-\frac{\|w\|}{2\tau}\right)$$



# Интуиция отбора признаков при L1-регуляризации



## L1-регуляризация и L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + r\alpha \sum_{i=0}^n |w_i| + (1 - r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2 =$   
 $\sum_i (w^T \cdot x^{(i)} - y_i)^2 + r\alpha \sum_{i=0}^n |w_i| + (1 - r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2$  — функция потерь

## L1-регуляризация и L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + r\alpha \sum_{i=0}^n |w_i| + (1-r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2 =$   
 $\sum_i (w^T \cdot x^{(i)} - y_i)^2 + r\alpha \sum_{i=0}^n |w_i| + (1-r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2$  — функция потерь
- Задача найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Свойства

- Нет аналитического решения
- Совмещает положительные свойства гребневой регрессии и LASSO.







## Мотивация

- Постановка задачи машинного обучения обычно начинается с определения метрики и фиксирования тестового датасета, на котором эта метрика будет считаться

## Мотивация

- Постановка задачи машинного обучения обычно начинается с определения метрики и фиксирования тестового датасета, на котором эта метрика будет считаться
- Неправильно выбранная метрика может затруднить использование модели машинного обучения в жизни и свести на нет усилия команды, разрабатывающей алгоритм машинного обучения.

## Мотивация

- Постановка задачи машинного обучения обычно начинается с определения метрики и фиксирования тестового датасета, на котором эта метрика будет считаться
- Неправильно выбранная метрика может затруднить использование модели машинного обучения в жизни и свести на нет усилия команды, разрабатывающей алгоритм машинного обучения.
- Как правило заказчик не мыслит в терминах метрик и может объяснить проблему, которую он хочет решить, только бизнес языком



## Мотивация

- Постановка задачи машинного обучения обычно начинается с определения метрики и фиксирования тестового датасета, на котором эта метрика будет считаться
- Неправильно выбранная метрика может затруднить использование модели машинного обучения в жизни и свести на нет усилия команды, разрабатывающей алгоритм машинного обучения.
- Как правило заказчик не мыслит в терминах метрик и может объяснить проблему, которую он хочет решить, только бизнес языком
- Понимание влияния выбора той или иной метрики на бизнес — это ключ к успешной постановки задачи



## Mean Square Error

$$MSE = \frac{1}{\ell} \sum_i (y_i - a(x_i))^2$$

# Метрики качества для задачи регрессии

## Mean Square Error

$$MSE = \frac{1}{\ell} \sum_i (y_i - a(x_i))^2$$

## Root Mean Square Error

$$RMSE = \sqrt{\frac{1}{\ell} \sum_i (y_i - a(x_i))^2}$$

# Метрики качества для задачи регрессии

## Mean Square Error

$$MSE = \frac{1}{\ell} \sum_i (y_i - a(x_i))^2$$

## Root Mean Square Error

$$RMSE = \sqrt{\frac{1}{\ell} \sum_i (y_i - a(x_i))^2}$$

## Mean Absolute Error

$$MAE = \frac{1}{\ell} \sum_i |y_i - a(x_i)|$$

## Max Error

$$ME = \max(|y_i - a(x_i)|)$$



# Метрики качества для задачи регрессии

## Max Error

$$ME = \max(|y_i - a(x_i)|)$$

## Mean Squared Logarithmic Error

$$MSLE = \frac{1}{\ell} \sum_i (\ln y_i - \ln a(x_i))^2$$

# Метрики качества для задачи регрессии

## Max Error

$$ME = \max(|y_i - a(x_i)|)$$

## Mean Squared Logarithmic Error

$$MSLE = \frac{1}{\ell} \sum_i (\ln y_i - \ln a(x_i))^2$$

## $R^2$ score

$$R^2 = 1 - \frac{\sum_i (y_i - a(x_i))^2}{\sum_i (y_i - \bar{y})^2},$$

где  $\bar{y} = \frac{1}{\ell} \sum_i y_i$



- Линейная регрессия — простая, хорошо интерпретируемая модель, не устойчивая к выбросам
- Имеет наглядную вероятностную интерпретацию
- Регуляризация — отличный способ борьбы с переобучением и шумом в данных

